

ES for Spikformer

从 EggRoll 复现停滞到 CIFAR-10 可训练信号

32.83%

best test acc

1M

population scale

0

non-lora update signal in old
EggRoll logs

这次汇报只回答一个问题

ES 能不能在 spike-style Transformer 上产生真实训练信号？

旧路线

EggRoll 0.1B / 32 generations 没有稳定候选差异

诊断任务

CIFAR-10 让初始化、loss、预测分布可诊断

规模门槛

population 直接放到 1,048,576

结构化参数

从 full model 转向当前 head / adapter / sparse head

结论：ES 信号已经成立，但 32.83% 不是最终成功；它只是说明下一步值得继续把搜索范围推向更接近表征层的参数化。

Source: 本报告目录下 Spikformer JSON ; Replay_EGGROLL paper_repro logs

旧 EggRoll 复现数据还在：它给的是负结果

任务	validation	fitness std 非零	LoRA update 非零	non-LoRA update
Countdown	1.00% flat	1 / 220 blocks	1 / 220 blocks	0 / 220
GSM8K	max 0.078%	2 / 500 blocks	2 / 500 blocks	0 / 500

可学习信号占比几乎为零

Countdown: std 非零 0.45%



GSM8K: std 非零 0.40%



Countdown: LoRA 更新 0.45%



GSM8K: LoRA 更新 0.40%



解读

本地 0.1B / 32 generations 基本没有候选差异和有效更新。

这不是正结果，但它解释了为什么后续转向 CIFAR-10/Spikformer 诊断任务。

实验重构：把 ES 问题搬到可校准的视觉任务

模型	Spikformer-4-256 style : $T = 4$, depth=4 , dim=256 , heads=8 , patch size=4 ; 4,159,274 params	
数据	CIFAR-10 : train 50k , test 10k ; 目标先看训练信号 , 不先追最终精度	
搜索	centered-rank antithetic ES ; population = 1,048,576 ; int8 fixed-point params ; best-state continuation	核心
部署	10.28.2.47 / NVIDIA H20 ; 共享 GPU 下用 chunk=128 , 关闭 JAX 预分配	
关键约束	保留 named parameter dictionary , 能区分 head、adapter、block , 不把结构信息压平	


改变不是“换一个数据集”，而是让每个训练阶段都有可解释的 sanity gate。

初始化 sanity gate：先让随机模型像随机模型

门槛	处理方式	意义：
logits std 进入 0.1–2.0	head 小初始化；必要时从 std=0.01 降到 0.001	
logits min/max 不爆炸	head 前 LayerNorm；避免 spike feature 直接把尺度传给 logits	
CE 接近 $\log(10) = 2.3026$	time / token / feature 聚合优先用 mean，不用 sum 放大 $T \times N \times D$	
softmax 不塌到 1.0	batch feature centering；保留 temperature 仅作诊断，不作为长期方案	
pred histogram 多类分布	每次架构改动先跑初始化 sanity script，再开 ES	

没有这个门槛，后面的 loss/accuracy 曲线没有解释价值；过大的 logits 会让 ES 先处理校准问题，而不是分类问题。

主结果：结构化 ES 把 best acc 推到 32.83%



读法：full model 不是主线；head-only 确认随机 trunk 有可读信息；adapter 是第一个可靠的非 head 突破口；sparse head 只提供小幅补偿。

路线演进：信号逐步从 head 推到非 head readout

1. Full model	2. Head-only	3. Frozen adapter	4. Adapter + head	最关
18.61%	28.16%	32.60%	32.83%	
4M 参数空间过大， sparse sign 信号稀 释	固定 trunk 后，线性 读出可被 ES 优化	pooled feature 后加 bottleneck adapter，进入非 head 参数	极稀疏 head 更新只 带来小幅补偿	

键的转折不是 32.83%，而是 head-only 之后还能靠 adapter 继续涨。

最有价值的证据：非 head 参数化贡献了 +4.44 pp

区间	增益	解释
Full model → Head-only	+9.55 pp	先把搜索降低维，证明系统里有分类信号
Head-only → Frozen adapter	+4.44 pp	不训练 head 也能提升，说明 ES 优化到了非 head readout 参数
Frozen adapter → Adapter + head	+0.23 pp	head 稀疏微调有用，但边际收益很低

+4.44
pp

这是当前阶段最应该在组会上强调的结果：ES 不只是把 classifier head 拧好，它已经能在 Spikformer-style pipeline 的结构化非 head 子空间里找到有效方向。

边界也很清楚：同一个 readout 已接近平台期

后续尝试	Best acc	Final loss	结论
Stage6, $\sigma = 0.025$, top 0.5%	32.60%	1.8753	loss 降，但 acc 不突破
Stage7, train head, top 0.1%	32.69%	1.8735	稀疏 head 有小增益
Stage8, train head, top 0.1%	32.83%	1.8727	当前 best，但幅度很小
Stage8, $\sigma = 0.0125$	32.74%	1.8734	小步长没有更好

判断：继续在同一个 pooled readout 上 continuation，主要是在改善 calibration/loss；要继续涨 accuracy，需要换更强的非 head 参数化。

Source: Stage6/Stage7/Stage8 result JSON ; current best artifact: runs/spikformer4_adapter_b64_b1024_stage8_trainhead_sigma025_top01_c128/best_state.npz

下一轮实验：把搜索范围推进表征层

- A. late-block adapter 在后 1–2 个 Spikformer block 加小 adapter，保留 trunk 结构信号，避免直接 full-model 4M 维扰动
- B. token-aware read-out 不要只用 pooled feature；让 adapter 看到 token 级统计或低秩 token mixer，测试 readout 表达能力是否是瓶颈
- C. 1M population 这个模型规模下，小 population 不能作为否定证据；1M 是当前判断基准
- D. 成功判据 不只看 loss 降：train/test acc 要继续涨，pred histogram 不塌缩，且非 head 参数贡献要能单独复现

短期

目标：从 readout adapter 推进到 late-block structured ES。